

Báo cáo Tái lập Thực nghiệm: BRISC — Brain Tumor MRI Dataset for Segmentation and Classification

Abstract

Báo cáo này trình bày kết quả chạy lại (reproduce) hai nhiệm vụ thực nghiệm của bài báo “*BRISC: Annotated Dataset for Brain Tumor Segmentation and Classification*” (Scientific Data, 2026): phân đoạn (segmentation) và phân loại (classification) khối u não trên ảnh MRI T1-weighted có cản quang. Em đã huấn luyện lại 12 mô hình phân đoạn và 13 mô hình phân loại trên cùng bộ dữ liệu BRISC, sau đó so sánh với các số liệu được công bố trong bài báo gốc. Do bài báo không công bố đầy đủ mã nguồn và siêu tham số huấn luyện chi tiết, thực nghiệm này được xem là một **independent reproduction** (tái lập độc lập, dựa trên mô tả phương pháp trong bài báo) thay vì một **exact reproduction** (tái lập chính xác từng bước). Vì vậy, các khác biệt quan sát được dưới đây nên được hiểu trong giới hạn đó, và các giải thích đưa ra mang tính giả thuyết hợp lý hơn là kết luận chắc chắn.

Contents

1	Giới thiệu	1
2	Phương pháp thực nghiệm	2
2.1	Dữ liệu	2
2.2	Cấu hình huấn luyện	2
3	Kết quả: Nhiệm vụ Phân đoạn (Segmentation)	2
3.1	So sánh và một số nhận định ban đầu	3
4	Kết quả: Nhiệm vụ Phân loại (Classification)	4
4.1	Bảng tổng hợp Weighted F1	4
4.2	Bảng chi tiết theo từng lớp (13 mô hình $\times$ 6 hàng)	4
4.3	Một số nhận định	8
5	Thảo luận chung	9
5.1	Hạn chế của báo cáo	9
6	Kết luận	9

1 Giới thiệu

Bộ dữ liệu BRISC [1] được giới thiệu nhằm khắc phục một số hạn chế của các bộ dữ liệu khối u não hiện có (như BraTS, Cheng), bao gồm mất cân bằng lớp, thiếu đa dạng, và nhãn không nhất quán. BRISC gồm 6.000 ảnh MRI T1-weighted có cản quang, được gán nhãn bởi bác sĩ X-quang và bác sĩ chuyên khoa, chia thành bốn lớp: *glioma*, *meningioma*, *pituitary* và *non-tumorous*.

Bài báo gốc cung cấp hai bộ kết quả benchmark:

- **Phân đoạn (segmentation):** 12 mô hình, đánh giá bằng mIoU theo từng loại u và mIoU có trọng số.
- **Phân loại (classification):** 13 mô hình CNN, đánh giá bằng Precision, Recall, F1-Score, Accuracy, lấy trung bình $\pm$ độ lệch chuẩn qua 3 lần chạy độc lập.

Mục tiêu của báo cáo là chạy lại hai bộ benchmark trên với cùng kiến trúc mô hình và bộ dữ liệu BRISC công khai trên Kaggle, từ đó đối chiếu với kết quả đã công bố và rút ra một số nhận định sơ bộ.

2 Phương pháp thực nghiệm

2.1 Dữ liệu

Bộ dữ liệu sử dụng giống mô tả trong bài báo gốc: 6.000 ảnh cho nhiệm vụ phân loại (5.000 train / 1.000 test) và 4.793 cặp ảnh–mặt nạ cho nhiệm vụ phân đoạn, tải trực tiếp từ Kaggle (briscdataset/brisc2025).

2.2 Cấu hình huấn luyện

- **Phân loại (classification):** các mô hình khởi tạo với trọng số pretrained ImageNet (qua timm), tối ưu hóa bằng AdamW, learning rate 10^{-4} , lịch trình CosineAnnealingLR, hàm mất mát Cross-Entropy có trọng số lớp, kèm early stopping (patience = 10) theo Validation F1.
- **Phân đoạn (segmentation):** các mô hình huấn luyện riêng theo từng loại u (Glioma, Meningioma, Pituitary), sử dụng hàm mất mát Dice + BCE kết hợp, lưu checkpoint tốt nhất theo IoU validation.
- **Số lần chạy:** do giới hạn phần cứng, mỗi mô hình phân loại trong thực nghiệm của em chỉ được chạy **1 lần**, trong khi bài báo gốc báo cáo trung bình của 3 lần chạy kèm độ lệch chuẩn.

3 Kết quả: Nhiệm vụ Phân đoạn (Segmentation)

Table 1: Kết quả Segmentation — Bài báo gốc (BRISC, 2026)

Model	Glioma (mIoU)	Meningioma (mIoU)	Pituitary (mIoU)	Weighted mIoU
UNet	69.7	77.1	79.3	75.7
UNet++	71.7	74.2	79.7	75.3
MANet	72.4	77.5	78.0	76.2
LinkNet	71.7	74.8	79.0	75.3
DeepLabV3+	72.0	77.5	78.7	76.3
PAN	72.0	74.5	80.7	75.9
EINet	73.6	78.4	80.3	77.7
EU-Net	71.7	76.1	78.3	75.6
DAD	75.2	80.4	82.3	79.5
BASNet	74.0	77.5	81.7	77.9
SaberNet	74.0	82.4	84.3	80.6
ABANet	72.4	80.4	84.7	79.5

Table 2: Kết quả Segmentation — Thực nghiệm tái lập (1 run)

Model	Glioma (mIoU)	Meningioma (mIoU)	Pituitary (mIoU)	Weighted mIoU
UNet	67.72	91.19	79.96	80.34
UNet++	67.65	91.26	81.27	80.80
MANet	68.68	91.05	81.23	81.02
LinkNet	65.74	90.86	79.30	79.41
DeepLabV3+	63.96	90.26	78.95	78.54
PAN	66.40	90.61	79.08	79.44
EU-Net	61.86	89.00	72.76	75.32
EINet	60.23	88.20	77.48	76.20
BASNet	63.46	90.44	79.80	78.76
DAD	61.44	89.01	75.76	76.25
SaberNet	64.42	89.63	76.55	77.62
ABANet	65.63	90.72	79.96	79.56

3.1 So sánh và một số nhận định ban đầu

Table 3: Chênh lệch Weighted mIoU (Thực nghiệm – Bài báo), %

Model	Bài báo	Thực nghiệm	Δ
UNet	75.7	80.34	+4.64
UNet++	75.3	80.80	+5.50
MANet	76.2	81.02	+4.82
LinkNet	75.3	79.41	+4.11
DeepLabV3+	76.3	78.54	+2.24
PAN	75.9	79.44	+3.54
EU-Net	75.6	75.32	-0.28
EINet	77.7	76.20	-1.50
DAD	79.5	76.25	-3.25
BASNet	77.9	78.76	+0.86
SaberNet	80.6	77.62	-2.98
ABANet	79.5	79.56	+0.06

Một điểm em quan sát được là lớp **Meningioma**: trong thực nghiệm của em, mIoU của lớp này dao động ổn định trong khoảng 88–91% ở mọi mô hình, cao hơn khá nhiều so với khoảng 74–82% được báo cáo trong bài báo gốc. Ngược lại, mIoU của lớp **Glioma** trong thực nghiệm của em (60–69%) lại thấp hơn bài báo gốc (69–75%) một cách khá hệ thống.

Em cho rằng có một vài giả thuyết hợp lý có thể giải thích phần nào sự khác biệt này, tuy chưa thể kiểm chứng chắc chắn do hạn chế về thông tin từ bài báo gốc:

1. **Đặc điểm hình thái khác nhau giữa các loại u:** U màng não (meningioma) thường có biên dạng tròn, ranh giới khá rõ. Trong khi đó, u thần kinh đệm (glioma) lại có cấu trúc không đồng nhất và mang tính xâm lấn, khuếch tán cao – đây vốn là một thử thách lớn đối với phần lớn các mô hình phân đoạn ảnh (segmentation models). Nếu có sự khác biệt trong bước tiền xử lý hoặc cách phân chia tập dữ liệu giữa hai lần thực nghiệm, độ khó khi xử lý glioma có thể bị phóng đại hơn rất nhiều so với meningioma.
2. **Khả năng kết quả gốc chỉ thu được từ một lần chạy duy nhất:** Bài báo không công bố số lần chạy lặp lại cho nhiệm vụ phân đoạn (không có cột std trong Table 3), nên

kết quả gốc có thể chịu ảnh hưởng của khởi tạo trọng số ngẫu nhiên ở một mức độ nào đó.

3. **Khác biệt cấu hình huấn luyện riêng theo từng loại u:** Vì các mô hình được huấn luyện tách biệt cho từng loại u, một thay đổi nhỏ về hàm mất mát hoặc số lượng epoch giữa các lớp có thể là lý do dẫn đến sự chênh lệch điểm số không đồng nhất như đã quan sát.
4. **Sự bất đồng bộ trong quá trình gán nhãn:** Do các mask được gán nhãn thủ công, sai số giữa những người gán nhãn thường có xu hướng cao hơn ở các khối u có hình thái phức tạp như glioma. Điều này có thể vô tình làm giảm điểm mIoU đo được, dù năng lực thực tế của mô hình không hề tệ.

Về **Weighted mIoU** tổng thể, 7/12 mô hình của em cho kết quả cao hơn bài báo gốc, phần lớn ở các kiến trúc CNN truyền thống (UNet, UNet++, MANet, LinkNet, DeepLabV3+, PAN, BASNet). Trong khi đó, một số mô hình được giới thiệu là "nâng cao" hơn trong bài báo gốc (DAD, SaberNet, EINet) lại cho kết quả thấp hơn trong thực nghiệm của em. Kết quả này cho thấy các kiến trúc mô hình phức tạp thường nhạy cảm hơn đối với cấu hình siêu tham số trong quá trình huấn luyện.

4 Kết quả: Nhiệm vụ Phân loại (Classification)

4.1 Bảng tổng hợp Weighted F1

Table 4: So sánh Weighted F1-Score — Bài báo gốc vs. Thực nghiệm tái lập

Model	Bài báo (mean $\pm$ std, 3 runs)	Thực nghiệm (1 run)
ResNet50	0.9820 $\pm$ 0.0080	0.9860
ResNet101	0.9810 $\pm$ 0.0092	0.9840
DenseNet121	0.5253 $\pm$ 0.3850	0.9870
DenseNet169	0.5710 $\pm$ 0.3689	0.9930
MobileNetV2	0.3237 $\pm$ 0.0264	0.9740
MobileNetV3	0.9447 $\pm$ 0.0140	0.9800
EfficientNetB0	0.9920 $\pm$ 0.0000	0.9850
EfficientNetB1	0.9903 $\pm$ 0.0042	0.9950
EfficientNetB2	0.9837 $\pm$ 0.0049	0.9890
Xception	0.1780 $\pm$ 0.0658	0.9920
VGG16	0.9693 $\pm$ 0.0177	0.9890
VGG19	0.9630 $\pm$ 0.0044	0.9880
InceptionV3	0.6487 $\pm$ 0.4312	0.9910

4.2 Bảng chi tiết theo từng lớp (13 mô hình $\times$ 6 hàng)

Để tiện đối chiếu, Bảng 5 và Bảng 6 trình bày đầy đủ kết quả theo từng lớp (glioma, meningioma, no_tumor, pituitary) cùng Macro/Weighted Average, của bài báo gốc và thực nghiệm tái lập tương ứng.

Table 5: Kết quả Classification chi tiết — Bài báo gốc (mean $\pm$ std, 3 runs)

Model	Class	Precision	Recall	F1-Score	Accuracy
ResNet50	glioma	0.9868 $\pm$ 0.0098	0.9751 $\pm$ 0.0164	0.9808 $\pm$ 0.0103	—
	meningioma	0.9815 $\pm$ 0.0150	0.9673 $\pm$ 0.0226	0.9741 $\pm$ 0.0087	—
	no_tumor	0.9906 $\pm$ 0.0107	0.9952 $\pm$ 0.0083	0.9929 $\pm$ 0.0035	—
	pituitary	0.9756 $\pm$ 0.0285	0.9967 $\pm$ 0.0000	0.9859 $\pm$ 0.0146	—
	Macro Avg	0.9836 $\pm$ 0.0064	0.9836 $\pm$ 0.0077	0.9834 $\pm$ 0.0072	—
	Weighted Avg	0.9823 $\pm$ 0.0076	0.9820 $\pm$ 0.0080	0.9820 $\pm$ 0.0080	0.9820 $\pm$ 0.0080
ResNet101	glioma	0.9726 $\pm$ 0.0347	0.9869 $\pm$ 0.0082	0.9794 $\pm$ 0.0138	—
	meningioma	0.9879 $\pm$ 0.0081	0.9575 $\pm$ 0.0279	0.9722 $\pm$ 0.0106	—
	no_tumor	0.9883 $\pm$ 0.0107	0.9905 $\pm$ 0.0165	0.9893 $\pm$ 0.0037	—
	pituitary	0.9793 $\pm$ 0.0113	0.9956 $\pm$ 0.0020	0.9874 $\pm$ 0.0066	—
	Macro Avg	0.9820 $\pm$ 0.0074	0.9826 $\pm$ 0.0093	0.9821 $\pm$ 0.0086	—
	Weighted Avg	0.9815 $\pm$ 0.0085	0.9810 $\pm$ 0.0092	0.9810 $\pm$ 0.0092	0.9809 $\pm$ 0.0092
DenseNet121	glioma	0.4838 $\pm$ 0.4753	0.5879 $\pm$ 0.5095	0.5197 $\pm$ 0.4731	—
	meningioma	0.6640 $\pm$ 0.5751	0.2800 $\pm$ 0.4569	0.3178 $\pm$ 0.4966	—
	no_tumor	0.5324 $\pm$ 0.4095	0.6976 $\pm$ 0.4871	0.4721 $\pm$ 0.4204	—
	pituitary	0.4502 $\pm$ 0.4128	0.6422 $\pm$ 0.5574	0.5259 $\pm$ 0.4678	—
	Macro Avg	0.5326 $\pm$ 0.4550	0.5519 $\pm$ 0.3376	0.4589 $\pm$ 0.4310	—
	Weighted Avg	0.5356 $\pm$ 0.4650	0.5253 $\pm$ 0.3850	0.5253 $\pm$ 0.3850	0.4531 $\pm$ 0.4390
DenseNet169	glioma	0.9543 $\pm$ 0.0690	0.3543 $\pm$ 0.5356	0.3840 $\pm$ 0.5173	—
	meningioma	0.7522 $\pm$ 0.2090	0.8007 $\pm$ 0.2607	0.7560 $\pm$ 0.2021	—
	no_tumor	0.4841 $\pm$ 0.4507	0.9738 $\pm$ 0.0393	0.5754 $\pm$ 0.3763	—
	pituitary	0.3333 $\pm$ 0.5774	0.3322 $\pm$ 0.5754	0.3328 $\pm$ 0.5764	—
	Macro Avg	0.6310 $\pm$ 0.3116	0.6152 $\pm$ 0.3305	0.5121 $\pm$ 0.4160	—
	Weighted Avg	0.6404 $\pm$ 0.3020	0.5710 $\pm$ 0.3689	0.5710 $\pm$ 0.3689	0.5093 $\pm$ 0.4169
MobileNetV2	glioma	0.3026 $\pm$ 0.0558	0.8517 $\pm$ 0.1229	0.4418 $\pm$ 0.0494	—
	meningioma	0.6667 $\pm$ 0.5774	0.0120 $\pm$ 0.0180	0.0233 $\pm$ 0.0348	—
	no_tumor	0.5343 $\pm$ 0.3066	0.6548 $\pm$ 0.1750	0.5249 $\pm$ 0.0899	—
	pituitary	0.1412 $\pm$ 0.2445	0.0400 $\pm$ 0.0693	0.0623 $\pm$ 0.1080	—
	Macro Avg	0.4112 $\pm$ 0.2078	0.3896 $\pm$ 0.0345	0.2631 $\pm$ 0.0307	—
	Weighted Avg	0.3980 $\pm$ 0.2379	0.3237 $\pm$ 0.0264	0.3237 $\pm$ 0.0264	0.2115 $\pm$ 0.0366
MobileNetV3	glioma	0.8912 $\pm$ 0.0353	0.9777 $\pm$ 0.0082	0.9321 $\pm$ 0.0154	—
	meningioma	0.9755 $\pm$ 0.0050	0.8639 $\pm$ 0.0334	0.9160 $\pm$ 0.0175	—
	no_tumor	0.9445 $\pm$ 0.0308	1.0000 $\pm$ 0.0000	0.9713 $\pm$ 0.0165	—
	pituitary	0.9679 $\pm$ 0.0073	0.9733 $\pm$ 0.0208	0.9706 $\pm$ 0.0138	—
	Macro Avg	0.9448 $\pm$ 0.0148	0.9537 $\pm$ 0.0113	0.9475 $\pm$ 0.0140	—
	Weighted Avg	0.9475 $\pm$ 0.0123	0.9447 $\pm$ 0.0140	0.9447 $\pm$ 0.0140	0.9442 $\pm$ 0.0142
EfficientNetB0	glioma	0.9960 $\pm$ 0.0000	0.9882 $\pm$ 0.0000	0.9921 $\pm$ 0.0000	—
	meningioma	0.9934 $\pm$ 0.0000	0.9869 $\pm$ 0.0000	0.9902 $\pm$ 0.0000	—
	no_tumor	0.9929 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.9964 $\pm$ 0.0000	—
	pituitary	0.9868 $\pm$ 0.0000	0.9967 $\pm$ 0.0000	0.9917 $\pm$ 0.0000	—
	Macro Avg	0.9923 $\pm$ 0.0000	0.9929 $\pm$ 0.0000	0.9926 $\pm$ 0.0000	—
	Weighted Avg	0.9920 $\pm$ 0.0000	0.9920 $\pm$ 0.0000	0.9920 $\pm$ 0.0000	0.9920 $\pm$ 0.0000
EfficientNetB1	glioma	0.9987 $\pm$ 0.0023	0.9921 $\pm$ 0.0000	0.9954 $\pm$ 0.0011	—
	meningioma	0.9933 $\pm$ 0.0001	0.9750 $\pm$ 0.0136	0.9840 $\pm$ 0.0070	—
	no_tumor	0.9976 $\pm$ 0.0041	1.0000 $\pm$ 0.0000	0.9988 $\pm$ 0.0021	—
	pituitary	0.9773 $\pm$ 0.0116	1.0000 $\pm$ 0.0000	0.9885 $\pm$ 0.0059	—
	Macro Avg	0.9918 $\pm$ 0.0036	0.9918 $\pm$ 0.0034	0.9917 $\pm$ 0.0036	—
	Weighted Avg	0.9905 $\pm$ 0.0040	0.9903 $\pm$ 0.0042	0.9903 $\pm$ 0.0042	0.9903 $\pm$ 0.0042

Table 5 – (tiếp theo)

Model	Class	Precision	Recall	F1-Score	Accuracy
EfficientNetB2	glioma	0.9919 ± 0.0040	0.9712 ± 0.0164	0.9814 ± 0.0091	—
	meningioma	0.9699 ± 0.0128	0.9782 ± 0.0105	0.9740 ± 0.0084	—
	no_tumor	0.9906 ± 0.0107	1.0000 ± 0.0000	0.9953 ± 0.0054	—
	pituitary	0.9879 ± 0.0082	0.9922 ± 0.0077	0.9900 ± 0.0017	—
	Macro Avg	0.9851 ± 0.0054	0.9854 ± 0.0047	0.9852 ± 0.0051	—
	Weighted Avg	0.9838 ± 0.0049	0.9837 ± 0.0049	0.9837 ± 0.0049	0.9837 ± 0.0049
Xception	glioma	0.0847 ± 0.1466	0.3333 ± 0.5774	0.1350 ± 0.2339	—
	meningioma	0.0000 ± 0.0000	0.0000 ± 0.0000	0.0000 ± 0.0000	—
	no_tumor	0.0933 ± 0.0808	0.6667 ± 0.5774	0.1637 ± 0.1418	—
	pituitary	0.0000 ± 0.0000	0.0000 ± 0.0000	0.0000 ± 0.0000	—
	Macro Avg	0.0445 ± 0.0165	0.2500 ± 0.0000	0.0747 ± 0.0230	—
	Weighted Avg	0.0346 ± 0.0259	0.1780 ± 0.0658	0.1780 ± 0.0658	0.0572 ± 0.0395
VGG16	glioma	0.9803 ± 0.0150	0.9396 ± 0.0741	0.9582 ± 0.0335	—
	meningioma	0.9427 ± 0.0509	0.9684 ± 0.0019	0.9549 ± 0.0257	—
	no_tumor	0.9790 ± 0.0068	0.9976 ± 0.0041	0.9882 ± 0.0020	—
	pituitary	0.9867 ± 0.0099	0.9822 ± 0.0117	0.9844 ± 0.0051	—
	Macro Avg	0.9722 ± 0.0132	0.9720 ± 0.0172	0.9714 ± 0.0162	—
	Weighted Avg	0.9706 ± 0.0157	0.9693 ± 0.0177	0.9693 ± 0.0177	0.9692 ± 0.0178
VGG19	glioma	0.9484 ± 0.0351	0.9541 ± 0.0421	0.9502 ± 0.0081	—
	meningioma	0.9624 ± 0.0130	0.9434 ± 0.0068	0.9527 ± 0.0030	—
	no_tumor	0.9725 ± 0.0231	0.9976 ± 0.0041	0.9848 ± 0.0111	—
	pituitary	0.9744 ± 0.0287	0.9745 ± 0.0267	0.9739 ± 0.0039	—
	Macro Avg	0.9645 ± 0.0061	0.9674 ± 0.0041	0.9654 ± 0.0047	—
	Weighted Avg	0.9639 ± 0.0039	0.9630 ± 0.0044	0.9630 ± 0.0044	0.9629 ± 0.0044
InceptionV3	glioma	0.6564 ± 0.5686	0.5315 ± 0.4983	0.5778 ± 0.5128	—
	meningioma	0.8972 ± 0.1694	0.6645 ± 0.5132	0.6401 ± 0.4458	—
	no_tumor	0.5887 ± 0.4180	0.9905 ± 0.0165	0.6719 ± 0.3794	—
	pituitary	0.6629 ± 0.5741	0.5722 ± 0.5136	0.6104 ± 0.5343	—
	Macro Avg	0.7013 ± 0.3670	0.6897 ± 0.3750	0.6250 ± 0.4676	—
	Weighted Avg	0.7225 ± 0.3490	0.6487 ± 0.4312	0.6487 ± 0.4312	0.6198 ± 0.4797

Table 6: Kết quả Classification chi tiết — Thực nghiệm tái lập (1 run)

Model	Class	Precision	Recall	F1-Score	Accuracy
ResNet50	glioma	0.9960	0.9764	0.9861	—
	meningioma	0.9771	0.9771	0.9771	—
	no_tumor	0.9859	1.0000	0.9929	—
	pituitary	0.9868	0.9967	0.9917	—
	Macro Avg	0.9865	0.9875	0.9870	—
	Weighted Avg	0.9860	0.9860	0.9860	0.9860
ResNet101	glioma	0.9841	0.9764	0.9802	—
	meningioma	0.9802	0.9706	0.9754	—
	no_tumor	0.9859	1.0000	0.9929	—
	pituitary	0.9868	0.9967	0.9917	—
	Macro Avg	0.9843	0.9859	0.9851	—
	Weighted Avg	0.9840	0.9840	0.9840	0.9840
DenseNet121	glioma	0.9919	0.9685	0.9801	—
	meningioma	0.9712	0.9902	0.9806	—

Table 6 – (tiếp theo)

Model	Class	Precision	Recall	F1-Score	Accuracy
	no_tumor	1.0000	1.0000	1.0000	—
	pituitary	0.9933	0.9933	0.9933	—
	Macro Avg	0.9891	0.9880	0.9885	—
	Weighted Avg	0.9871	0.9870	0.9870	0.9870
DenseNet169	glioma	0.9882	0.9921	0.9902	—
	meningioma	0.9902	0.9902	0.9902	—
	no_tumor	0.9929	1.0000	0.9964	—
	pituitary	1.0000	0.9933	0.9967	—
	Macro Avg	0.9928	0.9939	0.9934	—
	Weighted Avg	0.9930	0.9930	0.9930	0.9930
MobileNetV2	glioma	0.9917	0.9409	0.9657	—
	meningioma	0.9462	0.9771	0.9614	—
	no_tumor	0.9790	1.0000	0.9894	—
	pituitary	0.9867	0.9867	0.9867	—
	Macro Avg	0.9759	0.9762	0.9758	—
	Weighted Avg	0.9745	0.9740	0.9740	0.9740
MobileNetV3	glioma	0.9879	0.9606	0.9741	—
	meningioma	0.9644	0.9739	0.9691	—
	no_tumor	0.9790	1.0000	0.9894	—
	pituitary	0.9900	0.9933	0.9917	—
	Macro Avg	0.9803	0.9820	0.9811	—
	Weighted Avg	0.9801	0.9800	0.9800	0.9800
EfficientNetB0	glioma	0.9959	0.9567	0.9759	—
	meningioma	0.9650	0.9902	0.9774	—
	no_tumor	0.9929	1.0000	0.9964	—
	pituitary	0.9934	0.9967	0.9950	—
	Macro Avg	0.9868	0.9859	0.9862	—
	Weighted Avg	0.9853	0.9850	0.9850	0.9850
EfficientNetB1	glioma	0.9960	0.9921	0.9941	—
	meningioma	0.9902	0.9935	0.9918	—
	no_tumor	1.0000	1.0000	1.0000	—
	pituitary	0.9967	0.9967	0.9967	—
	Macro Avg	0.9957	0.9956	0.9956	—
	Weighted Avg	0.9950	0.9950	0.9950	0.9950
EfficientNetB2	glioma	0.9881	0.9843	0.9862	—
	meningioma	0.9805	0.9869	0.9837	—
	no_tumor	0.9929	1.0000	0.9964	—
	pituitary	0.9966	0.9900	0.9933	—
	Macro Avg	0.9896	0.9903	0.9899	—
	Weighted Avg	0.9890	0.9890	0.9890	0.9890
Xception	glioma	1.0000	0.9803	0.9901	—
	meningioma	0.9807	0.9967	0.9887	—
	no_tumor	1.0000	1.0000	1.0000	—
	pituitary	0.9933	0.9933	0.9933	—
	Macro Avg	0.9935	0.9926	0.9930	—
	Weighted Avg	0.9921	0.9920	0.9920	0.9920
VGG16	glioma	0.9960	0.9803	0.9881	—
	meningioma	0.9774	0.9902	0.9838	—
	no_tumor	0.9858	0.9929	0.9893	—

Table 6 – (tiếp theo)

Model	Class	Precision	Recall	F1-Score	Accuracy
	pituitary	0.9967	0.9933	0.9950	—
	Macro Avg	0.9890	0.9892	0.9890	—
	Weighted Avg	0.9891	0.9890	0.9890	0.9890
VGG19	glioma	0.9881	0.9803	0.9842	—
	meningioma	0.9901	0.9804	0.9852	—
	no_tumor	1.0000	1.0000	1.0000	—
	pituitary	0.9803	0.9967	0.9884	—
	Macro Avg	0.9896	0.9893	0.9895	—
	Weighted Avg	0.9880	0.9880	0.9880	0.9880
InceptionV3	glioma	0.9921	0.9843	0.9881	—
	meningioma	0.9901	0.9837	0.9869	—
	no_tumor	1.0000	1.0000	1.0000	—
	pituitary	0.9868	1.0000	0.9934	—
	Macro Avg	0.9923	0.9920	0.9921	—
	Weighted Avg	0.9910	0.9910	0.9910	0.9910

4.3 Một số nhận định

Khác biệt rõ nhất nằm ở nhóm các mô hình mà bài báo gốc báo cáo **độ lệch chuẩn rất lớn**: DenseNet121 (std = 0.385), DenseNet169 (std = 0.369), MobileNetV2 (F1 trung bình thấp), Xception (F1 trung bình chỉ 0.178), InceptionV3 (std = 0.431). Trong thực nghiệm của em, tất cả các mô hình này đều đạt F1 trên 0.97, khá nhất quán với nhóm mô hình "ổn định" còn lại của bài báo gốc.

Em nghĩ đây có thể là dấu hiệu của hiện tượng **huấn luyện không ổn định** (training instability) ở một số kiến trúc trong bài báo gốc, hơn là phản ánh hạn chế của bộ dữ liệu hoặc của các kiến trúc đó. Một vài hướng giải thích khả dĩ:

1. **Tốc độ học có thể chưa phù hợp với một số kiến trúc.** Các kiến trúc có kết nối dày đặc (DenseNet) hoặc nhiều nhánh song song (InceptionV3, Xception) thường nhạy hơn với learning rate cao hoặc thiếu giai đoạn warm-up. Std rất lớn trong Table 4 của bài báo gốc (gần bằng hoặc vượt giá trị trung bình) gợi ý khả năng trong 3 lần chạy có thể có 1-2 lần mô hình không hội tụ tốt, kéo trung bình xuống thấp.
2. **Cấu hình tối ưu hóa trong thực nghiệm của em có thể đã hỗ trợ ổn định huấn luyện hơn.** Em sử dụng AdamW kết hợp CosineAnnealingLR và trọng số pretrained ImageNet cho mọi kiến trúc; nhìn chung đây là cấu hình được biết đến là giúp huấn luyện ổn định hơn, nhưng em không có thông tin về cấu hình cụ thể bài báo gốc đã dùng để so sánh trực tiếp.
3. **Lớp no_tumor đạt 100% ở nhiều mô hình - khá nhất quán giữa hai thực nghiệm.** Bài báo gốc cũng ghi nhận Recall = 1.0000 ở EfficientNetB0/B1/B2, điều này hỗ trợ nhận định rằng đây là đặc điểm thực sự của dữ liệu (não không u có mẫu hình dễ phân biệt) chứ không phải lỗi đo lường riêng của thực nghiệm em.
4. **Hạn chế của việc chỉ chạy 1 lần.** Vì thực nghiệm của em chỉ chạy 1 lần cho mỗi mô hình, em không thể loại trừ khả năng lần chạy của mình rơi vào một kết quả tương đối thuận lợi trong phân phối biến thiên của mô hình. Để có cơ sở chắc chắn hơn, cần chạy lặp lại ít nhất 3 lần với các seed khác nhau, giống cách bài báo gốc đã làm.

5 Thảo luận chung

Tổng hợp hai nhiệm vụ, em có một vài nhận định sơ bộ sau:

- **Tính tái lập có thể chỉ đạt một phần.** Xu hướng tổng thể của bài báo gốc - rằng các kiến trúc nhẹ và hiện đại (EfficientNet, ResNet) cho kết quả phân loại ổn định và chính xác cao trên BRISC - bước đầu đã được xác thực qua thực nghiệm của em. Tuy nhiên, các con số tuyệt đối ở một số mô hình "không ổn định" trong bài báo gốc không tái lập một cách chính xác, và thực nghiệm của em cho kết quả tốt hơn và nhất quán hơn ở mọi kiến trúc.
- **Số lần chạy lặp lại có thể là yếu tố quan trọng.** Sự khác biệt lớn giữa hai bộ kết quả phân loại có khả năng liên quan nhiều đến độ ổn định của quy trình huấn luyện hơn là bản chất mô hình hay dữ liệu, dù em chưa thể khẳng định chắc chắn do giới hạn chỉ chạy 1 lần.
- **Khác biệt theo lớp u trong phân đoạn có thể liên quan đến đặc tính hình thái học.** Sự khác biệt hệ thống giữa Glioma (thấp hơn bài báo) và Meningioma (cao hơn bài báo) gợi ý một vài khả năng liên quan đến xử lý dữ liệu theo từng lớp hoặc đặc điểm hình thái khối u.

5.1 Hạn chế của báo cáo

- Thực nghiệm phân loại chỉ chạy 1 lần/mô hình do giới hạn phần cứng, nên không tính được độ lệch chuẩn để so sánh trực tiếp với bài báo gốc.
- Bài báo gốc không công bố đầy đủ mã nguồn và siêu tham số huấn luyện cụ thể cho từng mô hình, nên báo cáo này chỉ mang tính chất **independent reproduction**, không phải **exact reproduction**; một số khác biệt trong cấu hình huấn luyện giữa hai thực nghiệm có thể không được loại trừ hoàn toàn.

6 Kết luận

Báo cáo đã trình bày kết quả chạy lại hai benchmark (phân đoạn và phân loại) của bộ dữ liệu BRISC ở mức độ một independent reproduction. Đối với phân đoạn, kết quả của em cho thấy hiệu năng tổng thể (Weighted mIoU) tương đương hoặc nhỉnh hơn bài báo gốc ở phần lớn mô hình, nhưng có sự lệch khá rõ theo từng loại u (Meningioma cao hơn, Glioma thấp hơn), điều mà em chưa thể giải thích đầy đủ. Đối với phân loại, kết quả của em ổn định hơn khá nhiều so với bài báo gốc; sự khác biệt lớn ở một số mô hình (DenseNet, MobileNetV2, Xception, InceptionV3) trong bài báo gốc có thể xuất phát từ hiện tượng huấn luyện không ổn định, song đây vẫn là một giả thuyết cần thêm thực nghiệm (nhiều lần chạy) để xác nhận. Nhìn chung, các kết quả này gợi ý rằng bộ dữ liệu BRISC có thể hỗ trợ tốt việc huấn luyện các mô hình CNN hiện đại đạt độ chính xác cao, với điều kiện quy trình tối ưu hóa được thiết lập phù hợp.

References

- [1] Fateh, A., Rezvani, Y., Moayedi, S., Rezvani, S., Fateh, F., Fateh, M., & Abolghasemi, V. (2026). BRISC: Annotated Dataset for Brain Tumor Segmentation and Classification. *Scientific Data*, 13, 361. <https://doi.org/10.1038/s41597-026-06753-y>