

Báo cáo Đồ án: Hệ thống CAD Phân loại Hình thái Tinh trùng

Computer-Aided Diagnosis cho Đánh giá Vô sinh Nam dựa trên Ảnh Hiển vi SCD

Tóm tắt nội dung

Báo cáo trình bày hệ thống CAD phân loại hình thái tinh trùng từ ảnh SCD, dựa trên bộ dữ liệu Scientific Data (2026). Hai bài toán: Task A (Sperm vs Non-sperm, ResNet50, 650 ảnh) và Task B (phân loại 4 mức halo phản ánh mức độ phân mảnh DNA, EfficientNet-B0 2-stage fine-tuning, 403 ảnh). Áp dụng pipeline tiền xử lý 11 bước và các kỹ thuật chống overfitting cho dữ liệu nhỏ. Kết quả: Task A đạt Accuracy 0.9082, AUC 0.9704; Task B đạt Accuracy 0.7213, Macro F1 0.7262 — đều vượt baseline rõ rệt. Grad-CAM cho thấy mô hình tập trung đúng vào vùng đầu tinh trùng. Hạn chế: dữ liệu nhỏ, nhầm lẫn giữa các mức halo liền kề (đặc biệt lớp Medium), gợi ý hướng ordinal classification cho nghiên cứu tiếp theo.

Mục lục

1	Đặt vấn đề	Mục tiêu	3
2	Dữ liệu		3
2.1	Bộ dữ liệu gốc		3
2.2	Thông kê dataset sử dụng trong đồ án		4
2.3	Tiền xử lý ảnh (Preprocessing Pipeline)		4
3	Kiến trúc mô hình & Huấn luyện		6
3.1	Task A — Binary Classification (ResNet50)		6
3.2	Task B — Halo Multiclass Classification (EfficientNet-B0)		7
3.3	Các kỹ thuật chống overfitting được áp dụng		8
4	Kết quả thực nghiệm		9
4.1	Task A — Binary Classification		9
4.1.1	Kết quả đánh giá		9
4.1.2	Nhận xét		9
4.2	Task B — Halo Multiclass Classification		9
4.2.1	Kết quả đánh giá		9
4.2.2	Nhận xét		10
4.3	Explainability — Grad-CAM		10
5	Thảo luận chung		13

6	Hạn chế & Hướng cải thiện	14
7	Kết luận	15

1 Đặt vấn đề Mục tiêu

Vô sinh nam là một trong những nguyên nhân phổ biến ảnh hưởng đến khả năng sinh sản, trong đó chất lượng tinh trùng và mức độ phân mảnh DNA đóng vai trò quan trọng. Hiện nay, việc đánh giá ảnh hiển vi SCD chủ yếu được thực hiện thủ công, phụ thuộc vào kinh nghiệm của chuyên gia và mất nhiều thời gian. Sự phát triển của học sâu (Deep Learning) mở ra khả năng tự động hóa quá trình phân tích ảnh, góp phần nâng cao độ chính xác và tính khách quan trong chẩn đoán. Vì vậy, đề án này xây dựng một hệ thống Computer-Aided Diagnosis (CAD) nhằm hỗ trợ nhận diện tinh trùng và đánh giá mức độ phân mảnh DNA từ ảnh hiển vi SCD.

Đề án hướng đến việc xây dựng một hệ thống Computer-Aided Diagnosis (CAD) hỗ trợ phân tích ảnh hiển vi tinh trùng sử dụng phương pháp SCD bằng các mô hình học sâu. Các mục tiêu cụ thể gồm:

Xây dựng quy trình tiền xử lý và tăng cường dữ liệu nhằm nâng cao chất lượng ảnh đầu vào và cải thiện khả năng tổng quát của mô hình.

- Task A: Xây dựng mô hình ResNet50 cho bài toán phân loại nhị phân nhằm nhận diện tinh trùng và các đối tượng không phải tinh trùng.
- Task B: Xây dựng mô hình EfficientNet-B0 với chiến lược fine-tuning hai giai đoạn cho bài toán phân loại bốn mức halo, tương ứng với các mức độ phân mảnh DNA của tinh trùng.

Thông qua các mục tiêu trên, đề án xây dựng được một hệ thống CAD có khả năng hỗ trợ quá trình phân tích ảnh SCD một cách tự động, góp phần nâng cao tính khách quan và hiệu quả trong đánh giá chất lượng tinh trùng phục vụ chẩn đoán vô sinh nam.

2 Dữ liệu

Đề án sử dụng bộ dữ liệu *Expert-Annotated Optical Microscopy Images of Human Sperm for Detection and DNA Fragmentation Assessment* được công bố trên *Scientific Data* (2026). Bộ dữ liệu gồm ảnh hiển vi tinh trùng được chuẩn bị theo phương pháp Sperm Chromatin Dispersion (SCD), phục vụ hai bài toán chính: phân biệt tinh trùng và không phải tinh trùng, đồng thời phân loại tinh trùng theo bốn mức halo phản ánh mức độ phân mảnh DNA. Các nhãn dữ liệu được gán bởi các chuyên gia phôi học nhằm đảm bảo độ tin cậy.

2.1 Bộ dữ liệu gốc

Bộ dữ liệu bao gồm ba thành phần:

- (1) 435 ảnh hiển vi gốc chứa nhiều tinh trùng và các đối tượng khác;
- (2) tập phân loại nhị phân gồm 650 ảnh được gán nhãn *Sperm* và *Non-sperm*;
- (3) tập phân loại đa lớp gồm 403 ảnh tinh trùng được chia thành bốn mức halo (*Large*, *Medium*, *Small* và *Without halo*), phản ánh mức độ phân mảnh DNA của tinh trùng.

2.2 Thống kê dataset sử dụng trong đề án

Task A – Binary Classification (650 ảnh)

Tập	Non-sperm	Sperm	Tổng	Tỷ lệ
Train	230	224	454	69.8%
Validation	50	48	98	15.1%
Test	50	48	98	15.1%

Bảng 1: Phân bố dữ liệu của Task A

Task B – Halo Multiclass Classification (403 ảnh)

Tập	Large	Medium	Small	Without	Tổng
Train	71	75	64	71	281
Validation	16	16	14	15	61
Test	16	16	14	15	61

Bảng 2: Phân bố dữ liệu của Task B


2.3 Tiền xử lý ảnh (Preprocessing Pipeline)

Để nâng cao chất lượng dữ liệu đầu vào và tăng khả năng học của mô hình, đề án áp dụng pipeline tiền xử lý gồm 11 bước như sau:

1. **Đọc ảnh (Load Image):** Ảnh được đọc bằng thư viện OpenCV và chuyển từ không gian màu BGR sang RGB để thống nhất với các mô hình học sâu.
2. **Thay đổi kích thước (Resize):** Tất cả ảnh được đưa về kích thước 224×224 pixel nhằm phù hợp với đầu vào của ResNet50 và EfficientNet-B0.
3. **Chuyển đổi không gian màu:** Ảnh được chuyển sang không gian màu LAB hoặc HSV để hỗ trợ tăng cường tương phản và xử lý ảnh.
4. **Khử nhiễu (Bilateral Filter):** Sử dụng bộ lọc Bilateral nhằm giảm nhiễu nhưng vẫn bảo toàn biên của đầu tinh trùng và vùng halo.
5. **Tăng cường tương phản (CLAHE):** Áp dụng Contrast Limited Adaptive Histogram Equalization trên kênh sáng (L) để làm nổi bật các chi tiết của ảnh hiển vi.
6. **Chuẩn hóa nền (Background Normalization):** Loại bỏ ảnh hưởng của nền sáng không đồng đều bằng phép biến đổi Top-Hat kết hợp Gaussian Blur.
7. **Nhị phân hóa (Otsu Thresholding):** Sử dụng phương pháp Otsu để tự động xác định ngưỡng, tách vùng tinh trùng khỏi nền ảnh.
8. **Xử lý hình thái học (Morphology):** Áp dụng các phép Opening và Closing nhằm loại bỏ nhiễu nhỏ và lấp đầy các vùng bị khuyết.

9. **Trích xuất vùng quan tâm (ROI Extraction):** Xác định contour và lọc theo diện tích, tỷ lệ khung bao và độ tròn để giữ lại các vùng có khả năng chứa tình trùng.
10. **Tăng cường dữ liệu (Data Augmentation):** Trong quá trình huấn luyện, ảnh được biến đổi ngẫu nhiên bằng các phép lật, xoay, Affine Transform, thay đổi độ sáng, độ tương phản, Hue-Saturation, Gamma, thêm nhiễu Gaussian, Elastic Transform, Grid Distortion và Coarse Dropout nhằm tăng tính đa dạng của dữ liệu.
11. **Chuẩn hóa dữ liệu (Normalization):** Giá trị điểm ảnh được chuẩn hóa theo thống kê của ImageNet trước khi đưa vào mô hình học sâu.

3 Kiến trúc mô hình & Huấn luyện



Hình 1: Workflow xây dựng hệ thống

3.1 Task A — Binary Classification (ResNet50)

Task A được xây dựng nhằm giải quyết bài toán phân loại nhị phân giữa hai lớp *Sperm* và *Non-sperm*. Do số lượng mẫu của bộ dữ liệu tương đối nhỏ (650 ảnh), đề án lựa chọn phương pháp *transfer learning* thay vì huấn luyện mô hình từ đầu (training from scratch). Cụ thể, mô hình ResNet50 được sử dụng với trọng số khởi tạo từ bộ dữ liệu ImageNet nhằm tận dụng khả năng trích xuất đặc trưng đã được học từ một tập dữ liệu quy mô lớn.

Trong giai đoạn xây dựng mô hình, lớp phân loại (Fully Connected layer) mặc định của ResNet50 được thay thế bằng một classifier mới phù hợp với bài toán nhị phân. Kiến trúc classifier gồm một lớp Dropout với xác suất 0.3, tiếp theo là lớp Linear giảm số chiều đặc trưng từ 2048 xuống 256, hàm kích hoạt ReLU, một lớp Dropout với xác suất 0.2 và cuối cùng là lớp Linear có một nút đầu ra để dự đoán xác suất thuộc lớp *Sperm*. Giá trị đầu ra của mô hình được kết hợp với hàm BCEWithLogitsLoss, trong đó phép biến đổi sigmoid được tích hợp trực tiếp bên trong hàm mất mát để tăng tính ổn định số học trong quá trình huấn luyện.

Ở giai đoạn huấn luyện ban đầu, toàn bộ các lớp của backbone ResNet50 được đóng băng (freeze), chỉ cho phép cập nhật trọng số của classifier head mới được thêm vào. Cách tiếp cận này giúp giữ lại các đặc trưng đã học từ ImageNet, đồng thời giảm số lượng tham số cần tối ưu, từ đó hạn chế hiện tượng overfitting trên bộ dữ liệu có kích thước nhỏ.

Quá trình tối ưu mô hình sử dụng bộ tối ưu Adam với learning rate 1×10^{-4} và hệ số weight decay 1×10^{-4} . Mô hình được huấn luyện trong tối đa 20 epochs với kích thước batch là 32. Trong quá trình huấn luyện, bộ điều chỉnh learning rate ReduceLROnPlateau được sử dụng để tự động giảm tốc độ học khi giá trị hàm mất mát trên tập Validation không còn cải thiện. Đồng thời, kỹ thuật Early Stopping với patience bằng 5 được áp dụng nhằm dừng huấn luyện khi mô hình có dấu hiệu hội tụ, giúp giảm thời gian huấn luyện và hạn chế overfitting.

Sau mỗi epoch, mô hình được đánh giá trên tập Validation và checkpoint có kết quả tốt nhất sẽ được lưu lại để sử dụng trong quá trình kiểm thử. Cuối cùng, mô hình được đánh giá trên tập Test thông qua các chỉ số Accuracy, Precision, Recall, F1-score, AUC và Confusion Matrix nhằm đánh giá toàn diện hiệu quả của hệ thống.

3.2 Task B — Halo Multiclass Classification (EfficientNet-B0)

Task B giải quyết bài toán phân loại đa lớp nhằm xác định mức độ phân mảnh DNA của tinh trùng thông qua kích thước vùng halo trong ảnh SCD. Mỗi ảnh được phân vào một trong bốn lớp gồm *Large halo*, *Medium halo*, *Small halo* và *Without halo*. So với Task A, đây là bài toán khó hơn do sự khác biệt giữa các lớp chủ yếu nằm ở kích thước và hình thái của vùng halo, trong khi đặc điểm của đầu tinh trùng giữa các lớp gần như tương đồng.

Đề án lựa chọn EfficientNet-B0 làm backbone nhờ khả năng đạt hiệu quả cao với số lượng tham số tương đối nhỏ. Tương tự Task A, mô hình được khởi tạo bằng trọng số pretrained trên ImageNet để tận dụng các đặc trưng thị giác đã học trước, giúp cải thiện khả năng hội tụ trên bộ dữ liệu có kích thước nhỏ.

Lớp phân loại cuối của EfficientNet-B0 được thay thế bằng một classifier mới gồm lớp Dropout với xác suất 0.3, lớp Linear giảm số chiều đặc trưng từ 1280 xuống 256, hàm kích hoạt ReLU, tiếp theo là một lớp Dropout với xác suất 0.2 và lớp Linear gồm 4 nút đầu ra tương ứng với bốn lớp halo. Mô hình sử dụng hàm mất mát CrossEntropyLoss để thực hiện phân loại đa lớp.

Do bộ dữ liệu có sự chênh lệch nhẹ giữa số lượng mẫu của các lớp, đề án sử dụng

class weights trong hàm CrossEntropyLoss. Trọng số của từng lớp được tính theo tần suất nghịch đảo của số lượng mẫu, giúp mô hình giảm xu hướng thiên lệch về các lớp có nhiều dữ liệu hơn và tăng khả năng nhận diện các lớp ít mẫu, đặc biệt là lớp *Small halo*.

Khác với Task A, mô hình được huấn luyện theo chiến lược *2-stage fine-tuning*. Ở giai đoạn thứ nhất (Stage 1), toàn bộ backbone EfficientNet-B0 được đóng băng (freeze), chỉ huấn luyện classifier head mới được thêm vào. Learning rate được thiết lập ở mức 5×10^{-5} và mô hình được huấn luyện tối đa 50 epochs nhằm giúp lớp phân loại thích nghi với đặc trưng của bộ dữ liệu SCD mà không làm thay đổi các trọng số đã học từ ImageNet.

Sau khi Stage 1 hội tụ, mô hình chuyển sang Stage 2 bằng cách mở khóa (unfreeze) 10 lớp cuối của backbone EfficientNet-B0 để thực hiện fine-tuning. Learning rate được giảm xuống còn 5×10^{-6} , tức bằng một phần mười so với Stage 1. Việc giảm learning rate giúp các đặc trưng đã học từ ImageNet chỉ được điều chỉnh ở mức nhỏ, tránh hiện tượng *catastrophic forgetting* và đồng thời cho phép backbone học thêm các đặc trưng chuyên biệt của ảnh hiển vi SCD, đặc biệt là vùng halo bao quanh đầu tinh trùng.

Quá trình tối ưu sử dụng bộ tối ưu Adam kết hợp với bộ điều chỉnh learning rate ReduceLROnPlateau. Đồng thời, kỹ thuật Early Stopping với patience bằng 10 được áp dụng để dừng huấn luyện khi mô hình không còn cải thiện trên tập Validation. Sau mỗi epoch, mô hình có kết quả tốt nhất trên tập Validation được lưu lại và sử dụng để đánh giá trên tập Test.

Tổng số tham số của mô hình là khoảng 4,34 triệu, trong đó ở Stage 1 chỉ khoảng 329 nghìn tham số (khoảng 7,6%) được cập nhật. Chiến lược huấn luyện theo hai giai đoạn giúp mô hình vừa tận dụng được các đặc trưng tổng quát từ ImageNet, vừa thích nghi tốt với đặc trưng chuyên biệt của ảnh SCD, đồng thời hạn chế hiện tượng overfitting trên bộ dữ liệu có quy mô nhỏ.

3.3 Các kỹ thuật chống overfitting được áp dụng

Để nâng cao khả năng tổng quát hóa của mô hình trên bộ dữ liệu có kích thước nhỏ, đã áp dụng các kỹ thuật chống overfitting sau:

- Transfer Learning với trọng số pretrained trên ImageNet.
- Freeze backbone và fine-tuning theo từng giai đoạn.
- Data Augmentation để tăng tính đa dạng của dữ liệu.
- Dropout trong classifier head.
- Weight Decay (L2 Regularization) thông qua bộ tối ưu AdamW.
- Early Stopping để dừng huấn luyện khi mô hình không còn cải thiện.
- ReduceLROnPlateau để tự động giảm learning rate khi validation loss bão hòa.
- Model Checkpoint để lưu mô hình có hiệu năng tốt nhất trên tập Validation.

4 Kết quả thực nghiệm

4.1 Task A — Binary Classification

4.1.1 Kết quả đánh giá

Sau khi huấn luyện, mô hình ResNet50 được đánh giá trên tập kiểm thử (Test set). Kết quả thu được được trình bày trong Bảng 3.

Bảng 3: Kết quả đánh giá mô hình Task A

Chỉ số	Giá trị
Accuracy	90.82%
Precision	88.24%
Recall	93.75%
F1-score	90.91%
AUC	97.04%

Kết quả cho thấy mô hình đạt độ chính xác (Accuracy) 90.82% trên tập kiểm thử, đồng thời đạt F1-score 90.91%, phản ánh khả năng phân loại cân bằng giữa hai lớp *Sperm* và *Non-sperm*. Giá trị Recall đạt 93.75% cho thấy mô hình có khả năng nhận diện phần lớn các mẫu tinh trùng, hạn chế bỏ sót đối tượng cần phát hiện. Trong khi đó, Precision đạt 88.24%, chứng tỏ phần lớn các mẫu được dự đoán là tinh trùng đều chính xác.

Đặc biệt, chỉ số AUC đạt 97.04%, cho thấy mô hình có khả năng phân biệt hai lớp rất tốt trên nhiều ngưỡng phân loại khác nhau. Điều này chứng minh ResNet50 kết hợp với phương pháp Transfer Learning và pipeline tiền xử lý đã học được các đặc trưng hiệu quả của ảnh hiển vi tinh trùng.

4.1.2 Nhận xét

Kết quả thực nghiệm cho thấy mô hình ResNet50 đạt hiệu quả cao đối với bài toán phân loại nhị phân. Việc kết hợp Transfer Learning, Data Augmentation và các kỹ thuật chống overfitting như Dropout, Early Stopping và ReduceLROnPlateau giúp mô hình học được các đặc trưng quan trọng của ảnh hiển vi tinh trùng và duy trì khả năng tổng quát hóa tốt trên tập kiểm thử. Với Accuracy trên 90% và AUC đạt 97.04%, mô hình hoàn toàn có thể đóng vai trò là bước đầu trong hệ thống CAD, hỗ trợ tự động phát hiện tinh trùng trước khi thực hiện phân tích mức độ phân mảnh DNA ở Task B.

4.2 Task B — Halo Multiclass Classification

4.2.1 Kết quả đánh giá

Sau khi hoàn tất quá trình huấn luyện, mô hình EfficientNet-B0 được đánh giá trên tập kiểm thử (Test set). Kết quả đánh giá được trình bày trong Bảng 4.

Bảng 4: Kết quả đánh giá mô hình Task B

Chỉ số	Giá trị
Accuracy	72.13%
Macro F1-score	72.62%

Lớp	Precision	Recall
Large	90.9%	62.5%
Medium	52.2%	75.0%
Small	66.7%	57.1%
Without halo	93.3%	93.3%

Bảng 5: Precision, Recall, F1-score theo từng lớp — Task B (tính từ Confusion Matrix, Hình 4)

Kết quả cho thấy mô hình đạt Accuracy 72.13% và Macro F1-score 72.62% trên tập kiểm thử. Đây là kết quả khả quan đối với bài toán phân loại bốn lớp, trong đó sự khác biệt giữa các lớp chủ yếu nằm ở kích thước vùng halo và ranh giới giữa các mức halo thường không rõ ràng. Macro F1-score đạt trên 72% cho thấy mô hình duy trì được hiệu năng tương đối đồng đều giữa các lớp thay vì chỉ tập trung vào các lớp có nhiều mẫu.

4.2.2 Nhận xét

Nhìn chung, mô hình EfficientNet-B0 đạt hiệu quả tốt đối với bài toán phân loại bốn mức halo. Chiến lược huấn luyện theo hai giai đoạn (2-stage fine-tuning), kết hợp Transfer Learning, Data Augmentation và Class Weights đã giúp cải thiện khả năng tổng quát hóa trên bộ dữ liệu có quy mô nhỏ.

Mặc dù vẫn còn nhầm lẫn giữa các lớp *Medium Halo* và *Small Halo*, mô hình đạt kết quả ổn định trên hầu hết các lớp và đặc biệt nhận diện rất tốt lớp *Without Halo*. Kết quả thực nghiệm cho thấy phương pháp đề xuất có tiềm năng ứng dụng trong các hệ thống hỗ trợ chẩn đoán (CAD), góp phần tự động hóa quá trình đánh giá mức độ phân mảnh DNA của tinh trùng từ ảnh hiển vi SCD.

4.3 Explainability — Grad-CAM


Để tăng khả năng giải thích (Explainability) của mô hình học sâu, đồ án sử dụng phương pháp Gradient-weighted Class Activation Mapping (Grad-CAM) nhằm trực quan hóa các vùng ảnh có ảnh hưởng lớn đến quyết định dự đoán của mô hình. Grad-CAM hoạt động bằng cách tính gradient của lớp dự đoán đối với các đặc trưng ở lớp tích chập cuối cùng, sau đó tạo bản đồ nhiệt (heatmap) biểu diễn mức độ quan trọng của từng vùng trong ảnh.

Trong đồ án, Grad-CAM được áp dụng cho cả hai bài toán Task A và Task B. Đối với Task A, Grad-CAM được sử dụng để kiểm tra xem mô hình có thực sự tập trung vào vùng đầu tinh trùng thay vì nền ảnh hoặc các đối tượng không liên quan. Đối với Task B, Grad-CAM giúp đánh giá liệu mô hình có khai thác đúng vùng halo bao quanh đầu tinh trùng để phân biệt bốn mức độ phân mảnh DNA hay không.


Kết quả trực quan hóa cho thấy mô hình chủ yếu tập trung vào đầu tinh trùng và vùng halo xung quanh, đây cũng là những đặc trưng quan trọng được các chuyên gia sử dụng trong quá trình đánh giá mức độ phân mảnh DNA. Đối với các mẫu được dự đoán đúng, vùng kích hoạt có cường độ cao thường bao phủ chính xác khu vực halo. Trong khi đó, ở một số mẫu dự đoán sai, bản đồ nhiệt cho thấy mô hình bị ảnh hưởng bởi các vùng có hình thái tương tự hoặc các nhiễu trong ảnh, dẫn đến sự nhầm lẫn giữa các lớp, đặc biệt là giữa *Medium Halo* và *Small Halo*.

Việc sử dụng Grad-CAM không chỉ giúp kiểm chứng tính hợp lý của mô hình mà còn tăng mức độ tin cậy của hệ thống CAD, hỗ trợ người sử dụng hiểu được cơ sở đưa ra quyết định của mô hình thay vì chỉ nhận kết quả dự đoán.

Grad-CAM Explainability — Task Binary



Hình 2: Kết quả trực quan hóa Grad-CAM trên Task A




Hình 3: Kết quả trực quan hóa Grad-CAM trên Task B

5 Thảo luận chung

Kết quả thực nghiệm cho thấy các mô hình học sâu được lựa chọn đều đạt hiệu quả tốt trên bộ dữ liệu ảnh hiển vi SCD. Đối với Task A, mô hình ResNet50 đạt Accuracy 90.82% và AUC 97.04%, chứng tỏ khả năng phân biệt giữa tình trùng và các đối tượng không phải tinh trùng với độ tin cậy cao. Đây là bước tiền xử lý quan trọng giúp loại bỏ các đối tượng không liên quan trước khi thực hiện phân tích mức độ phân mảnh DNA.

Ở Task B, mô hình EfficientNet-B0 đạt Accuracy 72.13% và Macro F1-score 72.62%. Mặc dù kết quả thấp hơn Task A, đây vẫn là kết quả khả quan do bài toán phân loại bốn mức halo có độ khó cao hơn, khi ranh giới giữa các lớp không rõ ràng và đặc điểm hình thái của các lớp khá tương đồng. Kết quả theo từng lớp cho thấy mô hình nhận diện rất tốt lớp *Without Halo*, trong khi vẫn còn nhầm lẫn giữa các lớp *Medium Halo* và *Small Halo*.



Hình 4: Confusion Matrix Task B (Halo Multiclass Classification)

Phân tích confusion matrix cho thấy lớp Medium Halo có Precision thấp nhất (52.2) dù Recall khá cao (75.0), phản ánh xu hướng mô hình dự đoán "Medium" như một lựa chọn an toàn khi không chắc chắn: 5/16 mẫu Large và 6/14 mẫu Small bị phân loại nhầm thành Medium. Điều này củng cố nhận định rằng ranh giới giữa các mức halo mang tính liên tục (ordinal) hơn là rời rạc, và là cơ sở cho hướng cải tiến ordinal classification được đề xuất ở phần Hạn chế.

Việc kết hợp Transfer Learning, Data Augmentation, Fine-tuning theo hai giai đoạn và các kỹ thuật chống overfitting đã giúp mô hình đạt khả năng tổng quát hóa tốt trên bộ dữ liệu có kích thước nhỏ. Bên cạnh đó, Grad-CAM cho thấy mô hình chủ yếu tập trung vào vùng đầu tinh trùng và vùng halo khi đưa ra dự đoán, góp phần nâng cao tính giải thích và độ tin cậy của hệ thống.

6 Hạn chế & Hướng cải thiện

Mặc dù đạt được những kết quả khả quan, đề án vẫn còn một số hạn chế. Thứ nhất, bộ dữ liệu sử dụng có quy mô tương đối nhỏ, đặc biệt ở Task B chỉ gồm 403 ảnh, làm hạn chế khả năng học của mô hình và tăng nguy cơ overfitting. Thứ hai, dữ liệu được thu thập từ một nguồn duy nhất nên chưa phản ánh đầy đủ sự đa dạng về điều kiện chụp, thiết bị và chất lượng ảnh trong thực tế. Ngoài ra, mô hình vẫn còn nhầm lẫn giữa các

lớp có đặc điểm halo gần giống nhau, đặc biệt là *Medium Halo* và *Small Halo*.

Trong tương lai, có thể mở rộng bộ dữ liệu bằng cách thu thập thêm ảnh từ nhiều trung tâm xét nghiệm khác nhau nhằm tăng tính đa dạng và khả năng tổng quát hóa của mô hình. Bên cạnh đó, có thể nghiên cứu áp dụng các kiến trúc hiện đại hơn như ConvNeXt, Vision Transformer (ViT) hoặc Swin Transformer để nâng cao hiệu quả phân loại. Việc kết hợp cơ chế Attention, Ensemble Learning hoặc Semi-supervised Learning cũng là những hướng tiếp cận tiềm năng. Ngoài ra, hệ thống có thể được phát triển thành một ứng dụng hỗ trợ chẩn đoán, tích hợp giao diện trực quan và khả năng xử lý ảnh hiển vi theo thời gian thực.

7 Kết luận

Đồ án đã xây dựng thành công một hệ thống Computer-Aided Diagnosis (CAD) hỗ trợ phân tích ảnh hiển vi tinh trùng sử dụng phương pháp Sperm Chromatin Dispersion (SCD) dựa trên học sâu. Hệ thống gồm hai bài toán chính: phân loại nhị phân giữa tinh trùng và đối tượng không phải tinh trùng bằng ResNet50, và phân loại bốn mức halo phản ánh mức độ phân mảnh DNA bằng EfficientNet-B0.

Kết quả thực nghiệm cho thấy mô hình ResNet50 đạt Accuracy 90.82% và AUC 97.04%, trong khi EfficientNet-B0 đạt Accuracy 72.13% và Macro F1-score 72.62%. Các kết quả này cho thấy phương pháp đề xuất có khả năng hỗ trợ hiệu quả quá trình phân tích ảnh SCD, góp phần giảm thời gian đánh giá thủ công và tăng tính khách quan trong chẩn đoán.

Bên cạnh đó, việc sử dụng Grad-CAM giúp trực quan hóa vùng ảnh mà mô hình sử dụng khi đưa ra quyết định, qua đó nâng cao khả năng giải thích và độ tin cậy của hệ thống. Những kết quả đạt được là cơ sở để tiếp tục phát triển các hệ thống CAD có khả năng hỗ trợ bác sĩ trong đánh giá chất lượng tinh trùng và chẩn đoán vô sinh nam trong tương lai.

Tài liệu

- [1] Saadat, H., Borna, M.-R., & Torkashvand, H. (2026). Expert-Annotated Optical Microscopy Images of Human Sperm for Detection and DNA Fragmentation Assessment. *Scientific Data*, 13, 168. <https://doi.org/10.1038/s41597-025-06486-4>